

Concevoir et déployer
une plateforme IA agentique souveraine

3h

DURÉE TOTALE

1

Présentation

Architecture orale, 10 min

2

Schéma d'architecture

Diagram technique détaillé

3

Docker Compose

Stack fonctionnelle en une commande

01 Contexte

Une entreprise de **services numériques RH** (3 000 clients entreprises, 500 000 utilisateurs finaux) déploie depuis six mois des **agents IA internes** pour automatiser des workflows métier : génération de fiches, aide à la conformité, support employé.

Ces agents traitent des données personnelles sensibles — fiches de paie, évaluations, profils salariés. Les appels aux LLM cloud actuels posent un **problème de conformité RGPD** identifié par la DPO : des données nominatives circulent hors du périmètre sécurisé.

La Direction Digitale vous demande de **concevoir et déployer une alternative souveraine** : une stack IA entièrement auto-hébergée, observable, et réutilisable par les équipes techniques.

- Données RH sensibles
- Souveraineté RGPD
- Agents IA existants
- Auto-hébergé
- Azure AKS cible

02 Stack imposée

Open WebUI
INTERFACE

Interface de chat interne pour les utilisateurs finaux. Remplace ChatGPT dans l'environnement sécurisé.

Ollama
INFÉRENCE LLM

Serveur d'inférence local. Aucun token ne quitte l'infrastructure. Modèle(s) au choix du candidat.

Langfuse
OBSERVABILITÉ

Traçabilité complète des appels LLM : inputs, outputs, tokens, latence, évaluations. Self-hosté.

Les dépendances nécessaires au fonctionnement de ces services (bases de données, volumes, réseau interne) sont à inclure et à justifier. Tout autre composant additionnel doit être motivé.

03 Livrables attendus

1	Présentation de l'architecture 10 minutes de présentation orale devant le jury. Format libre : slides, tableau blanc, notes structurées. L'objectif est de convaincre la Direction Digitale d'adopter cette stack. – Justification des choix techniques au regard des enjeux business – Explication claire de la réponse à la contrainte de souveraineté – Identification des limites et risques de la solution proposée – 5 minutes de questions-réponses incluses
2	Schéma d'architecture Un diagramme technique clair, à remettre en PDF ou image. Outil au choix (draw.io, Excalidraw, Miro, à main levée scanné...). – Tous les composants de la stack représentés – Flux de données entre les composants (sens et protocole) – Ports exposés et réseau interne identifiés – Distinction explicite entre ce qui reste dans le périmètre et ce qui en sort
3	docker-compose.yml fonctionnel Un fichier <code>docker-compose.yml</code> qui démarre l'ensemble de la stack avec une seule commande, sans configuration manuelle supplémentaire. – Les 3 services imposés opérationnels et accessibles – Dépendances et ordre de démarrage gérés (<code>depends_on</code>) – Variables d'environnement et secrets externalisés proprement – Volumes persistants pour les données – Un README indiquant les commandes de démarrage et les URLs d'accès

04 Critères d'évaluation

Pertinence architecturale 30 % Les choix techniques répondent aux contraintes métier. Les composants s'articulent logiquement. Les limites sont connues et assumées.	Docker Compose 30 % La stack démarre sans intervention. Configuration propre, secrets bien gérés, volumes persistants, ordre de démarrage correct.
Schéma d'architecture 20 % Le diagramme est lisible et complet : composants, flux, ports, périmètre de sécurité. Un jury non-technique doit pouvoir le comprendre.	Communication orale 20 % Clarté de la présentation, capacité à défendre les choix, réponses aux questions. La solution est vendable à une direction.

05 Format & modalités

DURÉE DE PRÉPARATION

3 heures

en autonomie

RESTITUTION

30 minutes

présentation + questions

RESSOURCES AUTORISÉES

**Documentation en ligne, outils
habituels**pas de LLM externe pour la
conception

Rappel : L'objectif n'est pas une solution parfaite mais une solution **réfléchie et défendable**. La capacité à identifier ce qui manque ou ce qui pourrait poser problème en production est aussi valorisée que la complétude du livrable.