

Plateforme IA souveraine

Test technique — IA & Architecture

Alban Andrieu

Senior Cloud • DevSecOps • AI Architect

POC auto-hébergé : Open WebUI • LiteLLM • Ollama • Langfuse

1. Contexte métier

Problème

- Données RH sensibles
- Contraintes RGPD
- Usage croissant des agents IA
- Besoin d'observabilité
- Risque de dépendance fournisseur


Objectif

Mettre à disposition une plateforme IA interne :

- souveraine
- réutilisable
- observable
- extensible
- simple à démarrer

L'objectif n'est pas de produire une plateforme parfaite, mais une architecture défendable, évolutive et démontrable.

2. Vue d'architecture



Composants clés



User Experience

Open WebUI • Cloudflare Access



AI Platform

LiteLLM • Ollama • RAG • Prompt Templates



Observability

Langfuse • Tracing • Scores • Sessions



Infrastructure

PostgreSQL • ClickHouse • Redis • MinIO

3. Réponse à la contrainte de souveraineté


Ce qui reste interne

- Prompts
- Documents
- Embeddings
- Réponses
- Traces / Sessions / Scores
- Modèles locaux

Ce qui sort




- Accès HTTPS via Cloudflare uniquement
- Pas d'appel LLM externe en mode souverain
- Pas d'exposition directe d'Ollama
- Pas d'exposition directe des bases

4. RAG et assistants métier



Démonstration POC


- CV candidat
- Fiche de poste Thiga
- Assistant spécialisé
- Analyse d'adéquation
- Score final
- Citations documentaires



5. Pourquoi LiteLLM ?

Décision

Ne pas coupler directement Open WebUI à Ollama.



Raisons

- Je connaissais déjà LiteLLM
- Validation d'Ollama avant Open WebUI
- Découplage UI / modèles
- API OpenAI compatible
- Routage et fallbacks
- Observabilité Langfuse
- Base pour guardrails
- Préparation multi-modèles

MCP n'a pas été intégré dans le POC par contrainte de temps. J'ai cependant déjà une base MCP presque prête : gitlab.com/AlbanAndrieu/fastapi-sample.





6. Observabilité

Langfuse

- Sessions
- Traces
- Tokens
- Latence
- Scores

LiteLLM

- Logs de requêtes
- État des modèles
- Routage
- Headers utilisateur



7. Sécurité

Actuel dans le POC

- Cloudflare Tunnel
- Isolation Docker
- API Keys
- SOPS pour `.env`
- Inférence locale
- Services backend non exposés

Durcissement futur

- Vault
- Keycloak / OIDC
- RBAC
- Filtrage prompt injection
- Pseudonymisation PII
- Network Policies
- GitOps / IaC

Le POC montre la trajectoire de sécurité ; il ne prétend pas être un environnement de production durci.


8. Compromis et limites

Décision	Bénéfice	Limite
Docker Compose	Démarrage rapide	Pas de haute disponibilité
Ollama	Souveraineté	Dépendance GPU
LiteLLM	Découplage	Composant supplémentaire
Open WebUI	Interface rapide	API interne peu documentée
Langfuse	Observabilité	Dépendances PostgreSQL / ClickHouse / MinIO
Cloudflare	Accès simple	Hors périmètre souverain

Un bon POC doit aussi montrer ce qui manque pour la production : HA, SSO, RBAC, sauvegardes, supervision et politiques réseau.

9. Roadmap vers une plateforme d'entreprise

Évolution proposée



Court terme

Stabiliser, documenter, scorer.

Moyen terme

SSO, Vault, monitoring.

Long terme

AKS, GitOps, multi-tenancy.

10. Conclusion

Objectifs atteints

- Plateforme auto-hébergée
- Inférence locale
- RAG fonctionnel
- Observabilité Langfuse
- Découplage modèles
- Bootstrap automatisé

Valeur pour la Direction Digitale

- Réduction du risque RGPD
- Maîtrise des données
- Base réutilisable
- Évolutivité vers AKS
- Gouvernance IA mesurable

Questions ?

Annexe — Questions probables

Pourquoi ne pas connecter directement Open WebUI à Ollama ?

Parce que LiteLLM découple l'interface des modèles, facilite le routage, les fallbacks, l'observabilité et prépare l'évolution vers d'autres providers.

Pourquoi Langfuse ?

Pour apporter une observabilité IA : traces, sessions, prompts, tokens, latence, coûts et scores.

Pourquoi Cloudflare hors périmètre souverain ?

Cloudflare apporte l'accès sécurisé, mais il reste un tiers externe. Les données IA et les traitements restent dans l'infrastructure interne.

Que manque-t-il pour la production ?

SSO, RBAC, Vault, sauvegardes, HA, monitoring, politiques réseau, durcissement conteneurs, tests de charge, scoring automatisé.